Guion de sustentación · 15 minutos

¿Qué revelan los datos detrás del café arábica? (1.070 lotes)

Analítica y Métodos Multivariados (MATE AMMV-1) · Escuela Colombiana de Ingeniería Julio Garavito

Expositores: Juan Sebastián Guayazán Clavijo · Diego Hernando Nocua González · Esteban Valente Arenas

Numeración de páginas: presentación actual de 40 diapositivas (orden acordado).

1. Ajustes antes de proyectar

• Láminas sobrantes: hecho. La presentación queda con 40 diapositivas; las plantillas y las láminas de Colombia se quitaron (el original de 89 está en la copia de seguridad).

• Caracteres UTF-8 rotos en las gráficas de K-means y Ward.D2: pendiente de verificar en la versión actual.

• Conclusiones: pendiente agregar los tres bloques de ACM, clustering y regresión. La lámina actual muestra PCA, agrupamiento, métodos no lineales y limitaciones.

• Orden de cierre: la demo Shiny (pág. 39) va antes de las conclusiones (pág. 40). La presentación no tiene lámina de «¡GRACIAS!», así que el cierre queda en conclusiones.

• Shiny: la app usa los 627 lotes de la matriz final (PC1 = 55,1 %), no los 1.070 lotes con PC1 = 67,2 %.

2. Distribución de tiempos (15:00)

Tiempo	Páginas	Contenido
0:00 – 0:45	1 – 2	Portada e introducción del problema
0:45 – 1:45	2 – 3	Diagnóstico del problema y calidad del dato
1:45 – 2:45	3 – 4	Pipeline metodológico y depuración multivariada
2:45 – 5:00	5 – 18	Preparación de datos y PCA: codo, cargas y biplot
5:00 – 6:15	19	Análisis de Correspondencias Múltiples (ACM)
6:15 – 8:00	20 – 30	Reducción no lineal: MDS, Kernel PCA, UMAP y t-SNE
8:00 – 10:00	31 – 34	Clustering: K-means, HDBSCAN y Ward.D2 (perfiles)
10:00 – 11:00	35	Clasificación supervisada: LDA vs. Random Forest
11:00 – 12:45	36 – 38	Regresión simple, diagnósticos y capacidad predictiva
12:45 – 13:30	40	Síntesis de conclusiones
13:30 – 15:00	39	Demo en vivo (app Shiny) y cierre

3. Guion detallado por expositor

GUION DE SUSTENTACIÓN • DURACIÓN TOTAL: 15 MINUTOS (3 EXPOSITORES)

¿Qué revelan los datos detrás del café arábica? (1.070 lotes)

Analítica y Métodos Multivariados (MATE AMMV-1) | Escuela Colombiana de Ingeniería Julio GaravitoExpositores: Juan Sebastián Guayazán Clavijo • Diego Hernando Nocua González • Esteban Valente Arenas

1. Ajustes Urgentes Antes de Proyectar (Checklist Técnico)

▪ Eliminar láminas sobrantes (Págs. 29 a 87): La exposición principal abarca las páginas 1 a 28. Las páginas 29–42 corresponden a láminas de respaldo/taller y las páginas 43–87 son plantillas sin editar ('Cafe bookstore project proposal'). Elimina las páginas 43–87 y guarda las 29–42 en un archivo aparte de anexos para preguntas.

▪ Corregir caracteres UTF-8 rotos en 2 gráficas: En K-means (pág. 17) aparece 'proyecci<U+00F3>n' y en Ward.D2 (pág. 19) aparece 'Ward.D2 <U+2014> muestra'. Cúbrelos con un cuadro color crema en Canva o reexporta desde R con encoding = 'UTF-8'.

▪ Completar la lámina de Conclusiones (Pág. 25): Actualmente solo muestra PCA y Limitaciones. Añade tres bloques breves para cerrar todo el flujo: ACM (origen y método de beneficio), Clustering (gradiente continuo sin grupos discretos, Silhouette ≈ 0,12) y Regresión (datos físicos no reemplazan la cata, R^2 test = 0,046).

▪ Invertir el orden de cierre (Págs. 26–28): Mueve 'Demo en vivo - Shiny' antes de la diapositiva final de '¡GRACIAS!' para cerrar la presentación con los créditos del equipo. Ten presente que Shiny proyecta sobre los 1.070 lotes completos (PC1 = 67,2%), mientras el PCA depurado de 666 lotes explica 54,3% en PC1.

2. Distribución de Tiempos y Láminas (15:00 Minutos)

Bloque

Expositor

Láminas

Tiempo

Ejes Temáticos

Bloque 1

Juan Sebastián Guayazán

Págs. 1 – 9

5:00 min(0:00–5:00)

Portada, Diagnóstico del problema, Metodología y PCA Lineal.

Bloque 2

Diego Hernando Nocua

Págs. 10 – 20

5:00 min(5:00–10:00)

ACM (categóricas), Reducción No Lineal (Kernel PCA, UMAP, t-SNE, MDS) y Clustering.

Bloque 3

Esteban Valente Arenas

Págs. 21 – 28

5:00 min(10:00–15:00)

Clasificación (LDA vs. RF), Regresión Simple/Múltiple, Conclusiones y Demo Shiny.

3. Guion Detallado por Expositor

Expositor 1 · Juan Sebastián Guayazán Clavijo

0:00 – 5:00 · Págs. 1–18 (portada, diagnóstico, metodología, PCA)

 [0:00 – 0:45] Págs. 1 – 2 — Portada e Introducción del Problema

> «Buenos días a todos. Hoy presentamos nuestro proyecto de Analítica y Métodos Multivariados titulado "¿Qué revelan los datos detrás del café arábica?", basado en el análisis de 1.070 lotes evaluados por el Coffee Quality Institute.

Nuestro objetivo fue ir más allá de los promedios simples para responder tres preguntas centrales: qué estructura latente tienen estos cafés, si existen tipologías naturales entre lotes y hasta qué punto podemos predecir su calidad en taza antes de catarlos.»

 [0:45 – 1:45] Pág. 3 — Diagnóstico del Problema y Calidad del Dato

> «Al auditar las 14 variables cuantitativas iniciales —10 atributos sensoriales, altitud, humedad y dos conteos de defectos— detectamos tres retos críticos:
>
> 1. Calidad del dato: 174 de los 1.070 lotes registran humedad igual a cero, un patrón atípico de captura en la fuente que decidimos reportar sin asumir ciegamente que fueran datos faltantes.
>
> 2. Complejidad y escalas: Diferencias de escala enormes (con la altitud en metros dominando la varianza frente a puntajes de 0 a 10) y alta colinealidad entre atributos sensoriales.
>
> 3. Estructura oculta: La necesidad de reducir dimensionalidad para comprobar si existen grupos naturales no visibles en el espacio original.»

 [1:45 – 2:45] Pág. 4 — Pipeline Metodológico y Depuración Multivariada

> «Para garantizar rigor estadístico diseñamos un flujo en cuatro etapas: aplicamos transformación Yeo-Johnson selectiva únicamente en las variables con asimetría mayor a 1 y estandarizamos todas las variables a media cero y varianza uno.

Posteriormente, calculamos distancias de Mahalanobis sobre un PCA exploratorio con umbral Chi-cuadrado al 97,5 %, retirando 404 lotes atípicos multivariados y, en la matriz final, 39 más que superan el mismo umbral y, en la matriz final, 39 más que superan el mismo umbral. Esto consolidó una matriz limpia de 627 lotes sobre la cual contrastamos métodos lineales, no lineales, de agrupamiento y supervisados.»

 [2:45 – 5:00] Págs. 5 – 9 — Análisis de Componentes Principales (PCA): Cargas, Codo y Biplot

> «En el PCA final sobre los 627 lotes y 8 variables clave, los dos primeros componentes capturan el 67,6 % de la varianza total y marcan claramente el codo del gráfico:
>
> • CP1 (55,1 %) representa la calidad sensorial global: los siete puntajes de catación (Aroma, Sabor, Retrogusto, Acidez, Cuerpo, Balance y Puntaje del Catador) apuntan en la misma dirección con cargas homogéneas entre -0,33 y -0,41.
>
> • CP2 (12,5 %) es prácticamente ortogonal y captura la altitud, con una carga de -0,99.

Al observar tanto la matriz de dispersión de CP1 a CP4 como el Biplot conjunto, el hallazgo clave es que los lotes forman una nube continua sin clústeres naturales separados: el PCA resume variación, pero no demuestra grupos discretos. Con esto claro, le doy paso a mi compañero para explorar las variables categóricas y las proyecciones no lineales.»

Expositor 2 · Diego Hernando Nocua González

5:00 – 10:00 · Págs. 19–34 (ACM, reducción no lineal, clustering)

 [5:00 – 6:15] Pág. 10 — Análisis de Correspondencias Múltiples (ACM)

> «Gracias. Para integrar las variables cualitativas de los 1.070 lotes —País de Origen, Método de Beneficio y Color del grano— ejecutamos un ACM. Sus dos primeras dimensiones acumulan el 23 %

de la inercia y revelan dos patrones estructurales muy claros en el mapa factorial:

• La Dimensión 1 (11,8 %) separa hacia la derecha los registros con metadatos incompletos (Proceso y Color Desconocido, que aportan más del 78 % de la contribución conjunta) frente a los lotes con trazabilidad completa.

• La Dimensión 2 (11,2 %) contrasta dos modelos productivos reales: arriba, Brasil fuertemente asociado a procesos Natural / Dry y Semi-washed; abajo, Colombia, Guatemala y México agrupados alrededor del beneficio Washed / Wet.»

 [6:15 – 8:00] Págs. 11 – 16 — Reducción No Lineal: Kernel PCA, UMAP, t-SNE y MDS

«Dado que el PCA lineal no mostró grupos separados, evaluamos si existían variedades curvas ocultas mediante cuatro técnicas no lineales:

• En Kernel PCA con kernel RBF (σ = 0,1) emerge una curvatura en arco entre componentes que sugiere relaciones no lineales, repartiendo la varianza en 5 ejes (y en la comparativa global, sobre la misma base de 1.070 lotes, el PCA lineal explica 67,2 % en CP1 y los kernels no lineales van de 22 % a 100 %).

• En UMAP (probando 15 y 5 vecinos) y t-SNE (con perplejidad 30 y 5), reducir la vecindad resalta microestructuras locales, pero en todos los casos persiste una nube continua sin fronteras nítidas, recordando además que sus ejes no tienen interpretación directa en las variables originales.

• Finalmente, el MDS No Métrico arroja un Stress de 6,1 % (por debajo del umbral de 10 %), y el diagrama de Shepard muestra que las distancias del mapa 2D reproducen bien las originales (correlación 0,956).»

 [8:00 – 10:00] Págs. 17 – 20 — Clustering: K-means, HDBSCAN y Jerárquico Ward.D2

«Para verificar cuantitativamente esta continuidad, contrastamos tres paradigmas de agrupamiento:

1. K-means (k = 3) obtiene una Silhouette promedio de apenas 0,116, con 104 lotes (9,7 %) con silueta negativa y polígonos fuertemente superpuestos.

2. HDBSCAN, basado en densidad, clasifica la mayoría de lotes como ruido (grupo 0) y solo aísla pequeños núcleos locales sin equivalencia comercial directa.

3. Clustering Jerárquico Ward.D2 sobre una muestra de 80 lotes ratifica el diagnóstico: Silhouette de 0,128 y concordancia moderada con K-means (ARI = 0,471). Aunque al cortar en k = 3 diferenciamos perfiles promedio —dos grupos altos alrededor de 82,8 puntos y un tercero inferior en 79,9 puntos—, la conclusión es contundente: la calidad del café arábica es un continuo, no categorías aisladas. Le cedo la palabra a Esteban para el modelado supervisado.»

Expositor 3 · Esteban Valente Arenas

10:00 – 15:00 · Págs. 35–40 (clasificación, regresión, Shiny, conclusiones)

 [10:00 – 11:00] Pág. 21 — Clasificación Supervisada: LDA vs. Random Forest

«Muchas gracias. Al pasar al enfoque supervisado definiendo niveles de calidad Alta, Media y Baja, contrastamos el enfoque clásico con Aprendizaje Automático.

En el mapa discriminante de LDA, las fronteras lineales muestran un solapamiento estructural esperado en la transición entre calidad Media y Alta. Por su parte, Random Forest revela mediante disminución media de exactitud que el Puntaje del Catador, el Balance y el Sabor son los indicadores con mayor poder discriminante, mientras la altitud por sí sola aporta muy poco a separar clases.»

 [11:00 – 12:45] Págs. 22 – 24 — Regresión Simple, Diagnósticos y Comparativa Clásico vs. AA/ML

«En regresión planteamos dos preguntas complementarias:

• Primero, en Regresión Lineal Simple (Puntaje.Total ~ Sabor), obtenemos un $R^2 = 0,8002$. Como validan los cuatro gráficos diagnósticos —linealidad estable, normalidad central en el Q-Q plot e identificación de lotes influyentes como el 1014—, esto describe cuánto pesa el sabor durante la cata, pero responde a una relación aritmética porque el puntaje total es la suma de los atributos sensoriales.

• Por eso dimos el siguiente paso: ¿podemos predecir esa nota ANTES de catar, usando solo variables físicas, defectos y origen? Al entrenar en el 75 % y evaluar en el 25 % de prueba, el R^2 cae drásticamente —afectado también por un lote atípico con puntaje real de 0 que se observa a la izquierda de la gráfica—. Aun así, Random Forest supera a la Regresión Lineal Múltiple en todas las métricas: cuadruplica el R^2 (0,046 frente a 0,012), reduce el MAE a 1,98 puntos y sigue mejor la diagonal roja. Mientras el modelo lineal confirma efectos significativos positivos de Altitud y Proceso Natural, y negativos de Defectos Categoría 2, Random Forest posiciona a la Altitud (20,6 %) y el País (17,1 %) como las variables pre-cata más influyentes.»

 [12:45 – 13:30] Pág. 25 — Síntesis de Conclusiones

«En síntesis, nuestro estudio deja cuatro hallazgos fundamentales: primero, el PCA resume el 66,8 % de la variabilidad en dos ejes interpretables (calidad sensorial y altitud); segundo, el ACM evidencia cómo el origen geográfico determina el método de beneficio; tercero, tanto métodos lineales como no lineales y de clustering demuestran que el café arábica se comporta como un gradiente continuo sin clústeres naturales; y cuarto, las variables físicas establecen el potencial base del grano, pero no reemplazan la evaluación sensorial en taza.»

 [13:30 – 15:00] Págs. 26 – 28 — Demo en Vivo (App Shiny) y Cierre

«Finalmente, para llevar este análisis a una herramienta práctica de control de calidad, desarrollamos esta aplicación interactiva en Shiny. Como ven en pantalla, un catador o comprador puede ingresar los 7 atributos sensoriales y la altitud de un lote nuevo.

Por detrás, la aplicación ejecuta exactamente nuestro pipeline —transformación Yeo-Johnson selectiva, estandarización Z-score y proyección sobre el espacio PCA de referencia de los 627 lotes (matriz final, PC1 = 55,1 %)— para ubicar el lote en tiempo real y calcular su percentil relativo dentro de la muestra. Con esto cerramos nuestra presentación y quedamos atentos a sus preguntas. Muchas gracias.»