Guion de presentación

Análisis multivariado de la calidad del café arábica

Analítica y Métodos Multivariados · AMMV-1

Escuela Colombiana de Ingeniería Julio Garavito · 2026-2

Juan Sebastián Guayazán · Esteban Valente Arenas · Diego Hernando Nocua González

DURACIÓN OBJETIVO - 10 MINUTOS | ALCANCE - DIAPOSITIVAS 1-11

JUAN	DIEGO	ESTEBAN
Apertura y demo	Metodología, PCA y K-means	HDBSCAN, clasificación y cierre

Hilo de la exposición

Partimos de una pregunta sobre los datos: ¿cómo resumir varias medidas de calidad y explorar patrones entre lotes sin confundir un resultado estadístico con una categoría comercial? Primero presentamos la base y su exploración; luego explicamos qué aportan PCA y los métodos de agrupamiento; finalmente aclaramos los límites de la clasificación y mostramos la herramienta interactiva.

Diapositiva 1 - Portada

Tiempo: 0:30 · Presenta: Juan

Buenas tardes. Somos Juan Sebastián Guayazán, Esteban Valente y Diego Nocua, estudiantes de Ingeniería Estadística. En este proyecto analizamos 1.070 lotes de café arábica del Coffee Quality Institute.

Queremos mostrar qué patrones aparecen al estudiar varias características del café al mismo tiempo, qué información podemos resumir y qué precauciones hay que tener al interpretar los grupos que producen los métodos de clustering.

> **TRANSICIÓN -** *Para entender por qué usamos estas herramientas, empecemos por el problema que encontramos en los datos.*

Diapositiva 2 - Diagnóstico del problema

Tiempo: 0:55 · Presenta: Juan

La base tiene muchas medidas: puntajes sensoriales, altitud, humedad y conteos de defectos. Si miramos cada variable por separado, podemos pasar por alto relaciones entre ellas; además, algunas están en escalas distintas.

En la exploración observamos que 174 de los 1.070 registros tienen Humedad igual a cero. Ese cero también aparece explícitamente en la fuente original. Los gráficos y el análisis de vecindades muestran que el patrón merece atención, pero no nos dicen por qué ocurrió. Por eso lo describimos como un valor atípico que requiere interpretación, no como un faltante confirmado.

> **TRANSICIÓN -** *Con ese diagnóstico organizamos el análisis en etapas, cuidando que cada método responda su propia pregunta.*

Diapositiva 3 - Metodología

Tiempo: 0:55 · Presenta: Diego

Primero exploramos las distribuciones, los valores extremos, la asimetría y las correlaciones. Para el PCA final trabajamos con ocho variables y 666 lotes: se excluyeron seis variables con inflación de ceros o efecto techo, y se retiraron 404 observaciones identificadas como atípicas multivariadas. La transformación Yeo-Johnson se aplicó selectivamente cuando la asimetría absoluta superaba uno; después estandarizamos las variables.

El clustering responde otra pregunta y usa otra matriz: conserva los 1.070 lotes, combina cuatro componentes principales exploratorios con indicadores de variables categóricas. Por eso sus grupos no son los mismos objetos que las clases de LDA y QDA, que se construyen a partir de puntajes sensoriales.

> **TRANSICIÓN -** *Veamos primero qué resume el PCA final.*

Diapositiva 4 - Análisis de componentes principales

Tiempo: 1:15 · Presenta: Diego

El PCA transforma variables relacionadas en nuevos ejes que resumen patrones de variación. En el ajuste final, la primera componente explica el 54,3 por ciento y la segunda el 12,6; juntas explican el 66,8 por ciento de la variación de estas ocho variables y estos 666 lotes.

La primera componente reúne principalmente siete puntajes sensoriales, que tienden a moverse en una dirección común. La segunda está dominada por la altitud. Esto nos ayuda a resumir la información y a visualizarla, pero no significa que el primer eje sea una certificación de calidad ni que el PCA haya descubierto grupos naturales.

> **ACCIÓN -** *Señalar el gráfico de varianza, luego el diagrama de cargas y el biplot.*

> **TRANSICIÓN -** *Resumir los datos no es lo mismo que formar grupos. Para eso probamos K-means.*

Diapositiva 5 - K-means

Tiempo: 1:10 · Presenta: Diego

K-means asigna cada lote al centro más cercano en la matriz completa. El método del codo se aplana gradualmente después de tres grupos, así que usamos k igual a tres como candidato exploratorio; no es un óptimo único demostrado por la curva.

En el dibujo cada punto tiene una sola asignación. Puede parecer que los colores se mezclan porque la matriz se proyecta en dos dimensiones y esa vista deja información fuera. El solapamiento visual no significa que un lote pertenezca a varios grupos.

La Silhouette promedio es 0,116 y 104 lotes tienen valor negativo: la separación es débil. Aunque las corridas encuentran soluciones parecidas, eso indica estabilidad del procedimiento, no que existan tres categorías comerciales. Los grupos requieren perfiles en las variables originales antes de asignarles una interpretación.

> **TRANSICIÓN -** *También probamos un método que busca zonas densas y puede dejar observaciones sin asignar.*

Diapositiva 6 - HDBSCAN

Tiempo: 0:55 · Presenta: Esteban

HDBSCAN busca regiones donde se concentran lotes parecidos y no obliga a incluir todos en un grupo. Con un tamaño mínimo de 20, encontró cinco grupos de 39, 52, 101, 96 y 89 lotes. Otros 693, el 64,8 por ciento, quedaron como ruido; aquí “ruido” significa que el método no los asignó a una región suficientemente densa, no que sean cafés de mala calidad.

Esta matriz no incluye Humedad y difiere de la que usa K-means. Por eso no presentamos sus etiquetas como equivalentes ni afirmamos que ambos métodos coincidan sin calcular una comparación válida.

TRANSICIÓN - *LDA y QDA hacen algo distinto: aprenden a reproducir unas clases que definimos previamente.*

Diapositiva 7 - LDA y QDA

Tiempo: 0:55 · Presenta: Esteban

Para estos clasificadores definimos clases mediante cortes por cuartiles de la suma de puntajes sensoriales. Luego usamos esos mismos puntajes entre los predictores y evaluamos el resultado en 267 lotes de prueba.

La exactitud fue 87,3 por ciento para LDA y 89,1 para QDA. Son resultados útiles para ver qué tan bien reproducen esos cortes. Como las clases se construyen a partir de variables que también entran al modelo, estas cifras no demuestran que los clusters de K-means sean separables ni validan categorías de calidad independientes.

TRANSICIÓN - *Por eso las cifras de los tres métodos no se deben poner en una competencia directa.*

Diapositiva 8 - Métricas de métodos distintos

Tiempo: 0:50 · Presenta: Esteban

Cada indicador responde una pregunta diferente. La exactitud de LDA y QDA mide reproducción de las clases definidas; Silhouette evalúa qué tan cerca queda cada lote de su propio grupo frente a otros; y el porcentaje de ruido de HDBSCAN indica cuántos lotes no se asignaron a sus regiones densas.

No son porcentajes equivalentes ni se pueden ordenar como si midieran lo mismo. Para comparar directamente dos particiones necesitamos las mismas observaciones y una medida de concordancia calculada con ambas asignaciones.

TRANSICIÓN - *Con estas limitaciones claras, resumimos lo que sí podemos concluir.*

Diapositiva 9 - Conclusiones

Tiempo: 1:00 · Presenta: Esteban

Primero, el PCA final resume parte importante de la variación: las dos primeras componentes explican 66,8 por ciento en los 666 lotes analizados. Segundo, el patrón de Humedad igual a cero aparece en 174 registros y en la fuente original; detectarlo no basta para conocer su causa.

Tercero, K-means produce una partición exploratoria con separación débil según Silhouette. HDBSCAN encuentra cinco grupos y deja muchos lotes como ruido. Cuarto, la exactitud de LDA y QDA describe qué tan bien reproducen cortes construidos con puntajes sensoriales.

En conjunto, estos análisis ayudan a explorar la base, pero no sustentan por sí solos las etiquetas Specialty, Premium o Commodity.

TRANSICIÓN - *Para cerrar, mostraremos cómo se puede explorar la posición de un lote nuevo en un espacio de referencia.*

Diapositiva 10 - Demostración de Shiny

Tiempo: 1:20 · Presenta: Juan

Esta aplicación permite cambiar los valores de un lote hipotético y ver cómo se proyecta en un PCA de referencia. Voy a ingresar algunos puntajes sensoriales y una altitud; la aplicación transforma y estandariza los valores con su propio flujo y muestra la posición y el percentil relativo del lote.

ACCIÓN - *Ajustar un conjunto de valores plausible y proyectarlo. Después cambiar un solo puntaje y observar cómo se mueve el punto.*

El percentil nos dice dónde queda frente a la muestra de referencia, no si el café está certificado como Specialty. Esta demostración usa un PCA independiente, ajustado con 1.070 lotes; no asigna ni valida los grupos de K-means o HDBSCAN.

Diapositiva 11 - Cierre

Tiempo: 0:15 · Presenta: Juan

Muchas gracias por su atención. En resumen, los métodos nos permiten mirar los datos desde ángulos distintos, siempre cuidando qué pregunta responde cada resultado. Quedamos atentos a sus preguntas.

Distribución del tiempo

Referencia para el ensayo. Ajusten el ritmo al tiempo disponible y a las preguntas.

Diapositiva	Presenta	Tiempo	Acumulado
1	Juan	0:30	0:30
2	Juan	0:55	1:25
3	Diego	0:55	2:20
4	Diego	1:15	3:35
5	Diego	1:10	4:45
6	Esteban	0:55	5:40
7	Esteban	0:55	6:35
8	Esteban	0:50	7:25
9	Esteban	1:00	8:25
10	Juan	1:20	9:45
11	Juan	0:15	10:00

Los tiempos son una guía para ensayar; pueden ajustarse según el ritmo del equipo y las preguntas del público.