Guion de presentación

Análisis multivariado de la calidad del café arábica

Analítica y Métodos Multivariados · AMMV-1

Escuela Colombiana de Ingeniería Julio Garavito · 2026-2

Juan Sebastián Guayazán · Esteban Valente Arenas · Diego Hernando Nocua González

Duración objetivo: 10 minutos · **Alcance:** diapositivas 1 a 11

Hilo de la exposición

Partimos de una pregunta sobre los datos: ¿cómo resumir varias medidas de calidad y explorar patrones entre lotes sin confundir un resultado estadístico con una categoría comercial? Primero presentamos la base y su exploración; luego explicamos qué aportan PCA y los métodos de agrupamiento; finalmente aclaramos los límites de la clasificación y mostramos la herramienta interactiva.

Diapositiva 1 - Portada

Tiempo: 0:30 · Presenta: Juan

Buenas tardes. Somos Juan Sebastián Guayazán, Esteban Valente y Diego Nocua, estudiantes de Ingeniería Estadística. En este proyecto analizamos 1.070 lotes de café arábica del Coffee Quality Institute.

Queremos mostrar qué patrones aparecen al estudiar varias características del café al mismo tiempo, qué información podemos resumir y qué precauciones hay que tener al interpretar los grupos que producen los métodos de clustering.

Transición: Para entender por qué usamos estas herramientas, empecemos por el problema que encontramos en los datos.

Diapositiva 2 - Diagnóstico del problema

Tiempo: 0:55 · Presenta: Juan

La base tiene muchas medidas: puntajes sensoriales, altitud, humedad y conteos de defectos. Si miramos cada variable por separado, podemos pasar por alto relaciones entre ellas; además, algunas están en escalas distintas.

En la exploración observamos que 174 de los 1.070 registros tienen Humedad igual a cero. Ese cero también aparece explícitamente en la fuente original. Los gráficos y el análisis de vecindades muestran que el patrón merece atención, pero no nos dicen por qué ocurrió. Por eso lo describimos como un valor atípico que requiere interpretación, no como un faltante confirmado.

Transición: Con ese diagnóstico organizamos el análisis en etapas, cuidando que cada método responda su propia pregunta.

Diapositiva 3 - Metodología

Tiempo: 0:55 · Presenta: Diego

Primero exploramos las distribuciones, los valores extremos, la asimetría y las correlaciones. Para el PCA final el pipeline fue el siguiente, en este orden: primero aplicamos la transformación Yeo-Johnson selectivamente a

las variables con asimetría absoluta mayor a uno; después estandarizamos; luego ajustamos un PCA exploratorio y calculamos distancias de Mahalanobis para detectar atípicos multivariados. Se retiraron 404 observaciones con distancia por encima del umbral. El resultado final es una matriz de 666 lotes y ocho variables.

Vale la pena precisarlo porque el orden importa: si estandarizamos antes de transformar, los parámetros de Yeo-Johnson quedan calculados sobre datos ya centrados y la corrección de asimetría pierde sentido. Se excluyeron además seis variables: tres por inflación de ceros y tres por efecto techo en 10.

Una aclaración sobre los 404 lotes retirados: el umbral chi² al 97.5% deja por construcción un ~2.5% residual marcado en la nube final — eso es esperado en cualquier dataset real y no indica un error del pipeline. Los 404 son los casos genuinamente problemáticos de la primera pasada; los ~16 que quedan (~2.5% de 666) no se retiran porque hacerlo iterativamente vaciaría los datos.

El clustering responde otra pregunta y usa otra matriz: conserva los 1.070 lotes, combina cuatro componentes principales exploratorios con indicadores de variables categóricas. Por eso sus grupos no son los mismos objetos que las clases de LDA y QDA, que se construyen a partir de puntajes sensoriales.

Transición: Veamos primero qué resume el PCA final.

Diapositiva 4 - Análisis de componentes principales

Tiempo: 1:15 · Presenta: Diego

El PCA transforma variables relacionadas en nuevos ejes que resumen patrones de variación. En el ajuste final, la primera componente explica el 54,3 por ciento y la segunda el 12,6; juntas explican el 66,8 por ciento de la variación de estas ocho variables y estos 666 lotes.

La primera componente reúne principalmente siete puntajes sensoriales, que tienden a moverse en una dirección común. La segunda está dominada por la altitud. Esto nos ayuda a resumir la información y a visualizarla, pero no significa que el primer eje sea una certificación de calidad ni que el PCA haya descubierto grupos naturales.

También revisamos los diagramas de dispersión entre pares de componentes — CP1 vs CP2, CP1 vs CP3, CP2 vs CP3 — para detectar si alguna combinación revelaba una estructura más clara. Ninguna mostró grupos separados nítidamente.

Acción: Señalar el gráfico de varianza, luego el diagrama de cargas y el biplot.

Transición: Resumir los datos no es lo mismo que formar grupos. Para eso probamos K-means.

Diapositiva 5 - K-means

Tiempo: 1:10 · Presenta: Diego

K-means asigna cada lote al centro más cercano en la matriz completa. El método del codo se aplana gradualmente después de tres grupos, así que usamos k igual a tres como candidato exploratorio; no es un óptimo único demostrado por la curva.

En el dibujo cada punto tiene una sola asignación. Puede parecer que los colores se mezclan porque la matriz se proyecta en dos dimensiones y esa vista deja información fuera. El solapamiento visual no significa que un lote pertenezca a varios grupos.

La Silhouette promedio es 0,116 y 104 lotes tienen valor negativo: la separación es débil. Aunque las corridas encuentran soluciones parecidas, eso indica estabilidad del procedimiento, no que existan tres categorías comerciales. Los grupos requieren perfiles en las variables originales antes de asignarles una interpretación.

Transición: También probamos un método que busca zonas densas y puede dejar observaciones sin asignar.

Diapositiva 6 - HDBSCAN

Tiempo: 0:55 · Presenta: Esteban

HDBSCAN busca regiones donde se concentran lotes parecidos y no obliga a incluir todos en un grupo. Usamos un tamaño mínimo de clúster de 20 — ese es un hiperparámetro que elegimos nosotros, no el método. Con ese valor encontró cinco grupos de 39, 52, 101, 96 y 89 lotes. Otros 693, el 64,8 por ciento, quedaron como ruido; aquí "ruido" significa que el método no los asignó a una región suficientemente densa, no que sean cafés de mala calidad.

Esta matriz no incluye Humedad y difiere de la que usa K-means. Por eso no presentamos sus etiquetas como equivalentes ni afirmamos que ambos métodos coincidan sin calcular una comparación válida.

Transición: LDA y QDA hacen algo distinto: aprenden a reproducir unas clases que definimos previamente.

Diapositiva 7 - Ward.D2 — Clustering Jerárquico

Tiempo: 1:00 · Presenta: Diego

El siguiente método es Ward.D2, que es clustering jerárquico aglomerativo. A diferencia de K-means, no necesita que le digamos cuántos grupos queremos al inicio: va uniendo los lotes de a pares y tríos, eligiendo siempre la fusión que menos aumenta la varianza interna de cada grupo.

Este dendrograma muestra 80 lotes de la muestra. Cada hoja es un lote; las ramas se van uniendo de abajo hacia arriba. La línea roja marca la altura donde cortamos el árbol para obtener k igual a tres grupos: uno de 15 lotes, uno de 42 y uno de 23. A esa misma altura el dendrograma podría leerse también como cuatro grupos, dependiendo de dónde se trace el corte exacto. Elegimos tres porque la diferencia de altura entre el tercer y cuarto salto era pequeña y el índice Silhouette con k=3 era ligeramente mejor que con k=4; sin embargo reconocemos que k=4 era una opción razonable y que la elección tiene un componente subjetivo.

El Silhouette promedio de Ward es 0,128, ligeramente mayor que el de K-means de 0,116. El ARI entre K-means y Ward es 0,471: coincidencia moderada. Que dos métodos con lógicas distintas lleguen a agrupaciones similares refuerza que hay una estructura real, aunque débil.

Transición: Veamos qué perfil tiene cada uno de esos tres grupos.

Diapositiva 8 - Perfiles de grupos — Ward.D2

Tiempo: 0:45 · Presenta: Diego

Aquí vemos los promedios de atributos sensoriales por grupo en la muestra de 80 lotes. El grupo 1, de 15 lotes, tiene los promedios más altos: 7,71 en aroma y 82,9 puntos totales — es el grupo de perfil sensorial más intenso en casi todos los atributos. El grupo 2, el más numeroso con 42 lotes, tiene 82,7 puntos y un perfil muy similar al grupo 1 pero levemente más bajo; es el grupo mayoritario con calidad alta pero sin el pico del grupo 1. El grupo 3, de 23 lotes, tiene los puntajes más bajos en los siete atributos con 79,9 puntos — sigue siendo café de buena calidad pero con notas sensoriales menos intensas que los otros dos grupos.

Podríamos describirlos como: lotes de perfil sensorial intenso, lotes de perfil sensorial moderado-alto, y lotes de perfil sensorial moderado. Pero enfatizamos que esta interpretación es exploratoria: las distribuciones se traslapan y los grupos 1 y 2 tienen perfiles muy parecidos. No podemos llamar a estos grupos Specialty, Premium o Commodity sin un criterio externo definido previamente.

El análisis jerárquico y K-means llegan a conclusiones similares: la estructura de agrupamiento existe, pero es débil.

Transición: Con estas limitaciones claras, resumimos lo que sí podemos concluir.

Diapositiva 9 - Demostración de Shiny

Tiempo: 1:20 · Presenta: Juan

Esta aplicación permite cambiar los valores de un lote hipotético y ver cómo se proyecta en un PCA de referencia. Voy a ingresar un perfil sensorial alto en todos los atributos — ojo que el máximo real en los datos es 8,8, no es posible escribir 9.

Acción: Ingresar los valores: Aroma 8,8 · Sabor 8,8 · Retrogusto 8,7 · Acidez 8,5 · Cuerpo 8,6 · Balance 8,7 · Puntaje Catador 8,8. La aplicación indica calidad Alta.

Con este perfil la aplicación nos dice calidad Alta. Tiene sentido, todos los puntajes están en el extremo superior de la distribución.

Acción: Cambiar Aroma a 7,5 y mostrar que el resultado sigue siendo Alta.

Ahora le bajo bastante el aroma, de 8,8 a 7,5 — y fíjense que sigue diciendo Alta. Esto es porque la primera componente principal es un promedio ponderado de los siete atributos sensoriales juntos; bajar uno solo no arrastra el puntaje compuesto fuera del rango Alto mientras los demás sigan altos. El modelo no te castiga por una sola nota baja si el resto del perfil está bien.

El percentil nos dice dónde queda este lote frente a la muestra de referencia, no si el café está certificado como Specialty. Esta demostración usa un PCA independiente, ajustado con 1.070 lotes; no asigna ni valida los grupos de K-means o HDBSCAN.

Transición: Con todo lo que vimos, estas son nuestras conclusiones.

Diapositiva 10 - Conclusiones

Tiempo: 1:00 · Presenta: Esteban

Primero, el PCA final resume parte importante de la variación: las dos primeras componentes explican 66,8 por ciento en los 666 lotes analizados. Segundo, el patrón de Humedad igual a cero aparece en 174 registros y en la fuente original; detectarlo no basta para conocer su causa.

Tercero, K-means produce una partición exploratoria con separación débil según Silhouette. Ward.D2 llega a una estructura similar con ARI de 0,471 respecto a K-means. HDBSCAN encuentra cinco grupos y deja muchos lotes como ruido.

En conjunto, estos análisis ayudan a explorar la base, pero no sustentan por sí solos las etiquetas Specialty, Premium o Commodity. Como limitación reconocemos que la interpretación de los grupos es exploratoria: los perfiles que describimos son promedios en la muestra de 80 lotes y no se validaron contra una clasificación externa. Para confirmar que los grupos 1, 2 y 3 corresponden a categorías comerciales reales haría falta una fuente externa de verdad — por ejemplo, precios de mercado o certificaciones de especialidad para esos mismos lotes.

Diapositiva 11 - Cierre

Tiempo: 0:15 · Presenta: Juan

Muchas gracias por su atención. En resumen, los métodos nos permiten mirar los datos desde ángulos distintos, siempre cuidando qué pregunta responde cada resultado. Quedamos atentos a sus preguntas.

Distribución del tiempo

Diapositiva	Presenta	Tiempo	Acumulado
1	Juan	0:30	0:30
2	Juan	0:55	1:25
3	Diego	0:55	2:20
4	Diego	1:15	3:35
5	Diego	1:10	4:45
6	Esteban	0:55	5:40
7	Diego	1:00	6:35
8	Diego	0:45	7:20
9	Juan	1:20	8:40
10	Esteban	1:00	9:40
11	Juan	0:15	9:55

Los tiempos son una guía para ensayar; pueden ajustarse según el ritmo del equipo y las preguntas del público.